

Norme

Vektorske norme

$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$ (1-norma)
 $\|\mathbf{x}\|_2 = (\sum_{i=1}^n |x_i|^2)^{1/2}$ (2-norma)
 $\|\mathbf{x}\|_\infty = \max_{i=1,2,\dots,n} |x_i|$ (∞ -norma ali max-norma)

Matrične norme

$\|A\|_1 = \max_{j=1,2,\dots,n} (\sum_{i=1}^m |a_{ij}|)$ (1-norma)
 $\|A\|_\infty = \max_{i=1,2,\dots,m} (\sum_{j=1}^n |a_{ij}|)$ (∞ -norma)
 $\|A\|_2 = \max_{i=1,\dots,m} \sqrt{\lambda_i A^T A}$ (spektralna norma)
 $\|A\|_F = (\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2)^{1/2}$ (Frobeniusova norma)

Sistemi linearnih enačb

Sistem $a_{i1}x_1 + a_{i2}x_2 + \dots + a_{in}x_n = b_i$ za $i = 1, \dots, m$ zapišemo kot $A\mathbf{x} = \mathbf{b}$, kjer $A = [a_{ij}] \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{b} \in \mathbb{R}^m$.

Naj bo $A\mathbf{x} = \mathbf{b}$, $(A + \delta A)(\mathbf{x} + \delta \mathbf{x}) = \mathbf{b} + \delta \mathbf{b}$ in $\kappa(A) = \|A^{-1}\| \|A\|$. Če je $\kappa(A) < 1$ je

$$\frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} \leq \frac{\kappa(A)}{1 - \kappa(A)} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta \mathbf{b}\|}{\|\mathbf{b}\|} \right).$$

Trikotni sistemi

Rešimo z **direktnim vstavljanjem** ($\mathcal{O}(n^2)$) od indeksa 1 do n (spodnje trikotna) oziroma od n do 1 (spodnje trikotna).

LU razcep

Za $A \in \mathbb{R}^{n \times n}$ sta ekvivalentni izjavi:

- Obstaja enolični razcep $A = LU$, kjer je L spodnje trikotna z enkami na diagonali in U nesingularna zgornje trikotna mat.
- Vse vodilne podmatrike $A(1 : k, 1 : k)$ so nesingularne.

Za vsako nesingularno matriko $A \in \mathbb{R}^n$ najdemo tako permutacijsko matriko P , da obstaja LU razcep za PA .

Če je matrika diagonalno dominantna ($|a_{ii}| \geq \sum_{j \neq i} |a_{ji}|$) po stolpcih in v vsaj enem stolpcu strogo diagonalno dominantna, pivotiranje ni potrebno.

$$A\mathbf{x} = \mathbf{b} \implies L\mathbf{y} = P\mathbf{b} \implies U\mathbf{x} = \mathbf{y}.$$

Pri matrični enačbi $AX = B$ rešujemo sistem enačb $A\mathbf{x}_i = \mathbf{b}_i$. $\det PA = \det L \det U = \prod_{i=1}^n U_{ii}$, $\det P = (-1)^k$, k število menjav.

Delno pivotiranje ($\mathcal{O}(n^3)$)

Začnemo z $A^{(1)} = A$ in $P = I$.

V j -tem koraku imamo matriko $A^{(j)}$ in v njej poiščemo $\max_{j \leq i \leq n} |A_{ij}^{(j)}|$ ter zamenjamo j -to vrstico z vrstico, kjer je največji element, v $A^{(j)}$, v P in v vseh $L_i, i < j$.
Nato izvedemo Gaussovo eliminacijo vrstic $j + 1, \dots, n$ na $A^{(j)}$ in dobimo $A^{(j+1)} = L_j A^{(j)}$, kjer je

$$L_j = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{j+1j} & & \\ & & \vdots & \ddots & \\ & & -l_{nj} & & 1 \end{bmatrix}, \quad l_{kj} = \frac{A_{kj}^{(j)}}{A_{jj}^{(j)}}.$$

Na koncu imamo $U = A^{(n)}$,

$$L = L_1^{-1} L_2^{-1} \dots L_n^{-1} = \begin{cases} l_{kj} & ; k > j \\ 1 & ; k = j \text{ in } LU = PA. \\ 0 & ; \text{sicer} \end{cases}$$

Kompletno pivotiranje ($\mathcal{O}(n^3)$)

Enako kot delno pivotiranje, le da iščemo $\max_{j \leq k, l \leq n} |A_{kl}^{(j)}|$ in zamenjamo ustrezni vrstici ter stolpca. Dobimo $PAQ = LU$.

Simetrični pozitivno definitni sistemi

$A \in \mathbb{R}^{n \times n}$ je simetrična pozitivno definitna, če $A = A^T$ in $\mathbf{x}^T A \mathbf{x} > 0 \quad \forall \mathbf{x} \in \mathbb{R}^n$.

$A \in \mathbb{R}^{n \times n}$ je simetrična pozitivno definitna $\iff A = A^T$ in vse lastne vrednosti A so pozitivne.

Za simetrično pozitivno definitno $A \in \mathbb{R}^{n \times n}$ obstaja nesingularna spodnje trikotna $V \in \mathbb{R}^{n \times n}$, da je $A = VV^T$ (**razcep Choleskega** ($\mathcal{O}(n^3)$)).

Tridiagonalni sistemi

Vse neničelne elemente tridiagonalne A lahko hranimo v treh stolpcih dolžine n . Tako dobimo LU razcep brez pivotiranja s prostorsko in časovno zahtevnostjo $\mathcal{O}(n)$, ki je sigurno dober, če je matrika strogo diagonalno dominantna.

Nelinearne enačbe

Rešujemo enačbe tipa $f(x) = 0$, $f : I \subseteq \mathbb{R} \rightarrow \mathbb{R}$.

Bisekcija

Če je $f : [a, b] \rightarrow \mathbb{R}$ zvezna in velja $f(a)f(b) < 0$, potem ima f na (a, b) vsaj eno ničlo.

Za natančnost ε potrebujemo $k \geq \log_2 \frac{|b-a|}{\varepsilon}$ korakov.

Navadna iteracija

Enačbo preoblikujemo v $x = g(x)$ in izvajamo iteracijo $x_{r+1} = g(x_r)$.

Naj bo $g(\alpha) = \alpha$ in naj za g na $I = [\alpha - \delta, \alpha + \delta]$ velja $|g(x) - g(y)| \leq m|x - y|$, $\forall x, y \in I$, kjer je $0 \leq m < 1$. Teda $\forall x_0 \in I$ zaporedje $x_{r+1} = g(x_r)$ konvergira k α . Velja tudi $|x_r - \alpha| \leq m^r |x_0 - \alpha|$ in $|x_{r+1} - \alpha| \leq \frac{m}{1-m} |x_r - x_{r-1}|$.

Naj bo $g(\alpha) = \alpha$ in g zvezno odvedljiva v α . Če je $|g'(\alpha)| < 1$, potem obstaja taka okolica I za α , da $\forall x_0 \in I$ zaporedje $x_{r+1} = g(x_r)$ konvergira k α .

Naj $(x_r)_{r=0}^\infty$ konvergira k α . Pravimo, da je red konvergence p , če $\exists C_1, C_2 > 0$, da za dovolj pozne člene velja $C_1 |x_r - \alpha|^p \leq |x_{r+1} - \alpha| \leq C_2 |x_r - \alpha|^p$.

Naj bo $g(\alpha) = \alpha$, g v okolici α p -krat zvezno odvedljiva, $|g^{(k)}| = 0$ za $k = 1, \dots, p-1$ in $g^{(p)}(\alpha) \neq 0$. Potem ima iterativna metoda $x_{r+1} = g(x_r)$ v bližini α red konvergence p .

Računanje $\sqrt{a}$: $g(x) = \frac{x^2+a}{2x}$

Tangentna (Newtonova) metoda

$$x_{r+1} = x_r - \frac{f(x_r)}{f'(x_r)}$$

Naj bo α enostavna ničla dvakrat zvezno odvedljive f . Potem obstaja okolica I točke α in $C > 0$, da tangentna metoda konvergira $\forall x_0 \in I$ in $|x_r - \alpha| \leq C(x_r - \alpha)^2$.

Če je ničla enostavna, je konvergenca vsaj kvadratična. Če je ničla m -kratna, je konvergenca vsaj linearna.

Naj bo f na $I = [a, \infty)$ dvakrat zvezno odvedljiva, naraščajoča in konveksna, ki ima ničlo v $\alpha \in I$. Potem je α edina ničla f na I in $\forall x_0 \in I$ tangentna metoda konvergira k α .

Sekantna metoda

$$x_{r+1} = x_r - \frac{f(x_r)(x_r - x_{r-1})}{f(x_r) - f(x_{r-1})}$$

Red konvergence je $p \approx 1,62$ (superlinearna konvergenca).

Polinomske enačbe

Enačbe tipa $p(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_0 = 0$.

Ko poznamo eno ničlo x_k , lahko naslednjo najdemo z iskanjem ničel $p(x)/(x - x_k)$ (redukcija). Delimo lahko s Hornerjevim algoritmom.

Uporabimo lahko prejšnje metode ali pa iščemo lastne

$$\text{vrednosti matrike } \begin{bmatrix} 0 & 1 & & & \\ & \ddots & \ddots & & \\ & & \ddots & \ddots & \\ & & & \ddots & 1 \\ -a_0/a_n & -a_1/a_n & \dots & -a_{n-1}/a_n & \end{bmatrix}.$$

Laguerrova metoda

Ponavljamo iteracijo $S_1 = \frac{p'(z_r)}{p(z_r)}$, $S_2 = \frac{p'(z_r)^2 - p(z_r)p''(z_r)}{p(z_r)^2}$, $z_{r+1} = z_r - \frac{n}{S_1 \pm \sqrt{(n-1)(nS_2 - S_1^2)}}$, kjer predznak izberemo

tako, da ima imenovalec čim večjo absolutno vrednost.

Če ima p same realne ničle, potem za poljuben z_0 Laguerrova metoda konvergira k levemu ali desnemu najbližjemu korenu, pri čemer si mislimo, da sta pozitivni in negativni krak realne osi povezana v neskončnosti. V primeru enostavne ničle je red konvergence v bližini ničle kubičen.

Metoda deluje tudi za kompleksne ničle.

Sistemi nelinearnih enačb

Enačbe tipa $\mathbf{F}(\mathbf{x}) = 0$, $\mathbf{F} : I \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^n$.

Navadna (Jacobiјеva) iteracija za sisteme

Sistem preoblikujemo v $\mathbf{x} = \mathbf{G}(\mathbf{x})$ in izvajamo iteracijo $\mathbf{x}_{k+1} = \mathbf{G}(\mathbf{x}_k)$.

Če obstaja $\Omega \subset \mathbb{R}^n$ z lastnostima:

- $\mathbf{x} \in \Omega \implies \mathbf{G}(\mathbf{x}) \in \Omega$,
- $\mathbf{x} \in \Omega \implies \rho(J_{\mathbf{G}}(\mathbf{x})) \leq q < 1$,
potem ima $\mathbf{G}(\mathbf{x}) = \mathbf{x} \vee \Omega$ natanko eno rešitev α , ki je limita zaporedja $\mathbf{x}_{k+1} = \mathbf{G}(\mathbf{x}_k)$ za poljuben $\mathbf{x}_0 \in \Omega$.

Za konvergenco je dovolj

- $\mathbf{x} \in \Omega \implies \mathbf{G}(\mathbf{x}) \in \Omega$,
- $\sum_{j=1}^n \left| \frac{\partial g_i(\mathbf{x})}{\partial x_j} \right| \leq m < 1$ za $i = 1, \dots, n$.

Obenem velja $\|\mathbf{x}_k - \alpha\| \leq \frac{m^k}{1-m} \|\mathbf{x}_1 - \mathbf{x}_0\|_{\infty}$.

Newtonova metoda za sisteme

$\mathbf{x}_{k+1} = \mathbf{x}_k - J_{\mathbf{F}}(\mathbf{x}_k)^{-1} \mathbf{F}(\mathbf{x}_k)$, $J_{\mathbf{F}}$ je Jacobijeva matrika
V praksi rešujemo sistem $J_{\mathbf{F}}(\mathbf{x}_k)(\mathbf{x}_{k+1} - \mathbf{x}_k) = -\mathbf{F}(\mathbf{x}_k)$.

Linearni problem najmanjših kvadratov

Dana je $A \in \mathbb{R}^{m \times n}$, $m > n$ in $\mathbf{b} \in \mathbb{R}^m$. Iščemo $\mathbf{x} \in \mathbb{R}^n$, da bo napaka $\|A\mathbf{x} - \mathbf{b}\|_2$ minimalna.
Privzamemo $\text{rank } A = n$, sicer rešitev ni enolična.

Rešitev normalnega sistema $A^T A \mathbf{x} = A^T \mathbf{b}$ je rešitev po metodi najmanjših kvadratov.

QR razcep

Naj bo $A \in \mathbb{R}^{m \times n}$, $m \geq n$, $\text{rank } A = n$. Potem obstaja enolični razcep $A = QR$, kjer je $Q \in \mathbb{R}^{m \times n}$ z ortonormiranimi stolpci in $R \in \mathbb{R}^{n \times n}$ zgornje trikotna s pozitivnimi diagonalnimi elementi.

Poznamo tudi razširjen QR razcep (Givens in Householder), kjer je $Q \in \mathbb{R}^{m \times m}$ z ortonormiranimi stolpci in $R \in \mathbb{R}^{m \times n}$ kvazi zgornje trikotna.

$A^T A \mathbf{x} = A^T \mathbf{b}$ in $A = QR \implies R \mathbf{x} = Q^T \mathbf{b}$ (zgornje trikoten s.)

Gram-Schmidtova ortogonalizacija ($\mathcal{O}(2mn^2)$)

$$\tilde{a}_1 = \frac{a_1}{\|a_1\|_2}$$

$$\tilde{a}_i = \frac{a_i - \sum_{j=1}^{i-1} r_{ij} \tilde{a}_j}{r_{ii}}$$

$$r_{ij} = \begin{cases} \langle a_i, \tilde{a}_j \rangle & ; i > j \\ \left\| a_i - \sum_{k=1}^{i-1} r_{ik} \tilde{a}_k \right\|_2 & ; i = j \\ 0 & ; \text{sicer} \end{cases}$$

Tedaj je $Q = [\tilde{a}_1 \quad \tilde{a}_2 \quad \dots \tilde{a}_n]$, $R = [r_{ij}]_{i,j=1}^n$ in $A = QR$.

Pri modificirani GSO pa spremenimo

$$r_{ij} = \begin{cases} \langle a_i - \sum_{k=1}^{j-1} r_{ik} \tilde{a}_k, \tilde{a}_j \rangle & ; i > j \\ \left\| a_i - \sum_{k=1}^{i-1} r_{ik} \tilde{a}_k \right\| & ; i = j \\ 0 & ; \text{sicer} \end{cases}$$

Modificirana GSO je numerično stabilnejša od klasične.

Givensove rotacije ($\mathcal{O}(3mn^2 - n^3)$)

Začnemo z matriko $A^{(1)} = A$.

V k -tem koraku za $i > j$ definiramo $c = \frac{A_{jj}^{(k)}}{\sqrt{A_{jj}^{(k)2} + A_{ij}^{(k)2}}}$,

$s = \frac{A_{ij}^{(k)}}{\sqrt{A_{jj}^{(k)2} + A_{ij}^{(k)2}}}$ in $R_k([j, i], [j, i])^T = \begin{bmatrix} c & s \\ -s & c \end{bmatrix}$, kjer so ostali

deli R_k enaki kot pri I .

Izračunamo $A^{(k+1)} = R_k^T A^{(k)}$ (izničimo člen na (i, j)).

Ponavljamo za vse $i > j, i < m, j < n$ po zaporednih stolpcih.

Na koncu imamo $R = A^{(k_{\max})}$,
 $Q = (R_{k_{\max}}^T \dots R_1^T)^T = R_1 \dots R_{k_{\max}}$ in $A = QR$.

Householderjeva zrcaljenja ($\mathcal{O}(2mn^2 - \frac{2}{3}n^3)$)

Začnemo z matriko $A^{(0)} = A$.

V i -tem koraku imamo

$\mathbf{y} = \begin{bmatrix} A_{(i+1)(i+1)}^k & A_{(i+1)(i+2)}^k & \dots & A_{(i+1)m}^k \end{bmatrix}^T$ in

definiramo $\mathbf{w} = [y_1 + \text{sgn}(y_1)\|\mathbf{y}\|_2 \quad y_2 \quad \dots \quad y_{m-i}]^T$,

$P_k = I - \frac{2}{\mathbf{w}^T \mathbf{w}} \mathbf{w} \mathbf{w}^T$ ter $\tilde{P}_k = \begin{bmatrix} I_i & 0 \\ 0 & P_k \end{bmatrix}$.

Izračunamo $A^{(k+1)} = \tilde{P}_k A^{(k)}$ (izničimo člene $(j, i) \forall j > i$).

Na koncu imamo $R = A^{(n)}$, $Q = (\tilde{P}_n \dots \tilde{P}_1)^T = \tilde{P}_1 \dots \tilde{P}_n$ in $A = QR$.

Singularni razcep

Za vsako $A \in \mathbb{R}^{m \times n}$, $m \geq n$ obstaja singularni razcep $A = U \Sigma V^T$, kjer sta $U \in \mathbb{R}^{m \times m}$ in $V \in \mathbb{R}^{n \times n}$ ortogonalni ter $\Sigma \in \mathbb{R}^{m \times n}$ kvazidiagonalna z elementi $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n$. Elementom σ_j pravimo singularne vrednosti matrike, stolpci U so levi singularni vektorji, stolpci V pa desni singularni vektorji.

Če je $A \in \mathbb{R}^{m \times n}$ in $\text{rank } A = n$, je minimum $\|A\mathbf{x} - \mathbf{b}\|_2$

dosežen pri $\mathbf{x} = \sum_{j=1}^n \frac{\mathbf{u}_j^T \mathbf{b}}{\sigma_j} \mathbf{v}_j$.

Naj bo $A \in \mathbb{R}^{m \times n}$, $m \geq n$ in $\text{rank } A > k$ in naj bo

$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$. Potem je

$\min_{\text{rank } B=k} \|B - A\|_2 = \|A_k - A\|_2 = \sigma_{k+1}$ in

$\min_{\text{rank } B=k} \|B - A\|_F = \|A_k - A\|_F = \sqrt{\sum_{i=k+1}^n \sigma_i^2}$.

Problem lastnih vrednosti

Za $A \in \mathbb{R}^{n \times n}$ iščemo $\mathbf{x} \in \mathbb{R}^n, \lambda \in \mathbb{R}$, da $A\mathbf{x} = \lambda \mathbf{x}$.

Potenčna metoda

$\mathbf{y}_{k+1} = A \mathbf{z}_k$, $\mathbf{z}_{k+1} = \frac{\mathbf{y}_{k+1}}{\|\mathbf{y}_{k+1}\|}$

Naj bo λ_1 dominanta lastna vrednost A

($|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$). Če ima vektor $\mathbf{z}_0$ neničelno komponento v smeri lastne vektorja, ki pripada λ_1 , potem zaporedje $(\mathbf{z}_k)$ po smeri konvergira k temu lastnemu vektorju.

Rayleighov koeficient: $\rho(\mathbf{x}, A) = \frac{\mathbf{x}^H A \mathbf{x}}{\mathbf{x}^H \mathbf{x}}$.

Iteracijo ustavimo, ko $\|A \mathbf{z}_k - \rho(\mathbf{z}_k, A) \mathbf{z}_k\| \leq \varepsilon$.

Rayleighjev koeficient je najboljši približek za lastno vrednost pri danem lastnem vektorju.

Hitrost konvergence je linearna in je hitrejša, če je $\frac{|\lambda_2|}{|\lambda_1|}$ majhno.

Hotelingova redukcija

Naj bo $A = A^T$ in $(\lambda_1, \mathbf{x}_1)$ dominantni lastni par A , kjer

$\|\mathbf{x}_1\|_2 = 1$. Tedaj za $B = A - \lambda_1 \mathbf{x}_1 \mathbf{x}_1^T$ velja $B \mathbf{x}_1 = 0$ in

$B \mathbf{x}_k = \lambda_k \mathbf{x}_k$ za $k \neq 1$.

Potenčna metoda na B nam torej da drugo dominantno lastno vrednost A .

B ne računamo eksplicitno, saj $B \mathbf{z} = A \mathbf{z} - \lambda_1 (\mathbf{x}_1^T \mathbf{z}) \mathbf{x}_1$.

Householderjeva redukcija

Poiščemo ortogonalno matriko Q , da je $Q \mathbf{x}_1 = k \mathbf{e}_1$

(Householderjevo zrcaljenje). Tedaj je

$B = Q A Q^T = \begin{bmatrix} \lambda_1 & \mathbf{b}^T \\ 0 & C \end{bmatrix}$, kjer se lastne vrednosti C ujemajo s

preostalimi lastnimi vrednostmi A .

Inverzna iteracija

Če iščemo najmanjšo lastno vrednost A lahko izvajamo potenčno metodo na A^{-1} . V praksi raje kot ekspliciten račun A^{-1} rešujemo sistem $A \mathbf{y}_{k+1} = \mathbf{z}_k$.

Če je σ približek za lastno vrednost, lahko pripadajoč lastni vektor dobimo z inverzno iteracijo na $A - \sigma I$.

QR iteracija

$A_0 = A$, $A_k = Q_k R_k$ (QR razcep), $A_{k+1} = R_k Q_k$

Če ima A lastne vrednosti s paroma različnimi absolutnimi vrednostmi, potem zaporedje (A_k) konvergira proti Schurovi formi.

Simetrične matrike

Simetrično matriko lahko ortogonalno podobno pretvorimo na simetrično tridiagonalno matriko (recimo s Householderjevimi zrcaljenji).

Sturmovo zaporedje

Naj bo $T = \begin{bmatrix} a_1 & b_1 & & \\ b_1 & a_2 & b_2 & \\ & \ddots & \ddots & \ddots \end{bmatrix}$ ireducibilna ($b_i \neq 0$)

tridiagonalna simetrična matrika in naj bo T_r njena vodilna podmatrika velikosti $r \times r$.

Definiramo $f_r(\lambda) = \det(T_r - \lambda I)$. Tedaj

$f_{r+1}(\lambda) = (a_{r+1} - \lambda)f_r(\lambda) - b_r^2 f_{r-1}(\lambda)$, kjer je $f_0(\lambda) = 1$ in $f_1(\lambda) = a_1 - \lambda$.

Polinomi f_r , $r = 0, 1, \dots, n$ tvorijo Sturmovo zaporedje, torej:

1. $f_0(\lambda) \neq 0, \forall \lambda$
2. $f_r(\lambda_0) = 0$ za $r < n \implies f_{r-1}(\lambda_0)f_{r+1}(\lambda_0) < 0$
3. $f_n(\lambda_0) = 0 \implies f_{n-1}(\lambda_0)f'_n(\lambda_0) < 0$

Ireducibilna tridiagonalna simetrična matrika ima enostavne lastne vrednosti.

Označimo z $u(\lambda_0)$ število ujemanj predznakov zaporednih členov v zaporedju $f_r(\lambda_0)$. Pri tem vsako notranjo ničlo štejemo za eno ujemanje, ničlo na koncu pa ne.

Število $u(\lambda_0)$ je enako številu lastnih vrednosti matrike T , ki so strogo večje od λ_0 .

Torej lahko k -to lastno vrednost poiščemo z bisekcijo (dober začetni interval je $[-\|A\|_\infty, \|A\|_\infty]$, saj $|\lambda| \leq \|A\|_\infty$).

Jacobijeva iteracija

Z Givensovimi rotacijami z leve in desne poskušamo matriko spremeniti v diagonalno.

Definiramo $\text{off } A = \sqrt{\sum_{j,k=1; j \neq k}^n |a_{jk}|^2}$.

Če je matrika A' dobljena iz A z enim korakom Jacobijeve iteracije na elementu (p, q) , je $\text{off}(A')^2 = \text{off}(A)^2 - 2a_{pq}^2$.

Z vsako rotacijo v iteraciji se torej $\text{off } A$ zmanjša. Postopek ponavljamo dokler ni $\text{off}(A) \leq \varepsilon$.

Izven diagonalne elemente lahko uničujemo po največji absolutni vrednosti (**klasična varianta**), vedno v enakem vrstnem redu (**ciklična varianta**) ali pa vedno v enakem vrstnem redu, a le elemente, ki presegajo neko predpisano absolutno vrednost (**pragovna varianta**).

Interpolacija

Dane so vrednosti f_i , $i = 0, 1, \dots, n$ v paroma različnih x_i . Iščemo interpolacijski polinom p najnižje stopnje za katerega velja $p(x_i) = f_i$, $i = 0, \dots, n$.

Za take podatke obstaja natanko en interpolacijski polinom p_n stopnje $\leq n$.

Klasična oblika

Zapišemo $p_n(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0$ in dobimo sistem enačb oblike

$a_n x_i^n + a_{n-1} x_i^{n-1} + \dots + a_1 x_i + a_0 = f_i$, $i = 0, 1, \dots, n$.

Sistem lahko rešimo z že znanimi metodami, vendar je slabo pogojen.

Lagrangeova oblika

$l_{n,i}(x) = \prod_{k=0, k \neq i}^n \frac{x - x_k}{x_i - x_k}$, $i = 0, 1, \dots, n$

Potem je $p_n(x) = \sum_{j=0}^n f_j l_{n,j}(x)$.

Če definiramo $\omega(x) = (x - x_0)(x - x_1) \cdots (x - x_n)$, potem

velja $l_{n,i}(x) = \frac{\omega(x)}{(x - x_i)\omega'(x_i)}$.

Če je f $(n+1)$ -krat zvezno odvedljiva na $[a, b]$, ki vsebuje vse paroma različne x_i , potem $\forall x \in [a, b] \quad \exists \xi \in (a, b)$, da je

$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega(x)$.

Newtonova oblika

Deljena diferenca $[x_0, x_1, \dots, x_k]f$ je vodilni koeficient interpolacijskega polinoma stopnje k , ki se ujema s funkcijo f v $x_0, x_1, \dots, x_k$.

$p_n(x) = [x_0]f + (x - x_0)[x_0, x_1]f + \dots + (x - x_0)(x - x_1) \cdots (x - x_{n-1})[x_0, x_1, \dots, x_n]f$

$[x_0, x_1, \dots, x_k]f = \frac{[x_1, x_2, \dots, x_k]f - [x_0, x_1, \dots, x_{k-1}]f}{x_k - x_0}$

Če točke x_i niso paroma različne, definiramo posplošeno deljeno diferenco

$[x_0, x_1, \dots, x_k]f = \begin{cases} \frac{f^{(k)}(x_0)}{k!} & ; x_0 = \dots = x_k \\ \frac{[x_1, \dots, x_k]f - [x_0, \dots, x_{k-1}]f}{x_k - x_0} & ; \text{sicer} \end{cases}$

Tedaj bo Newtonov interpolacijski polinom p_n interpoliral še pripadajoče odvode.

Naj bo f $(n+1)$ -krat zvezno odvedljiva funkcija in p_n interpolacijski polinoma na točkah x_i , $i = 0, 1, \dots, n$ (če se točke ponavljajo, polinom interpolira ustrezne višje odvode).

Potem je $f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega(x)$, kjer je

$\min\{x, x_0, \dots, x_n\} \leq \xi \leq \max\{x, x_0, \dots, x_n\}$.

$\omega(x) = (x - x_0)(x - x_1) \cdots (x - x_{n-1})(x - x_n)$

Numerično odvajanje

Radi bi numerično izračunali odvod zvezno odvedljive $f : [a, b] \rightarrow \mathbb{R}$ v $c \in [a, b]$.

Metoda nedoločenih koeficientov

Poznamo vrednost funkcije v okoliških točkah x_j , $j = 0, 1, \dots, k$

in nastavimo $f'(c) \approx \sum_{j=0}^k \alpha_j f(x_j)$. Vrednosti koeficientov določimo tako, da za f vstavimo neke znane funkcije, najpogostejše kar x^n , $n = 0, 1, \dots, k$.

Podobno velja za višje odvode.

Najlažje rešujemo z ekvidistančnimi točkami, tedaj dobimo

$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h} \approx \frac{f(x+h) - f(x)}{h}$

$f''(x) \approx \frac{f(x+h) - 2f(x) + f(x-h)}{h^2} \approx \frac{f(x+2h) - 2f(x+h) + f(x)}{h^2}$

Za numeričen približek odvoda lahko vzamemo tudi **odvod interpolacijskega polinoma za f v c** ali **odvod ustreznega zleпка za f na [a, b]** v c.

Navadne diferencialne enačbe

Rešujemo $y'(x) = f(x, y(x))$, $y(a) = y_a$.

V splošnem na intervalu $[a, b]$ izberemo ekvidistantne delilne točke $a = x_0 < x_1 < \dots < x_N = b$, kjer je $h = x_{i+1} - x_i$, in iščemo $y_i \approx y(x_i)$.

Lokalna napaka je $y_{n+1} - z(x_{n+1})$, kjer je z rešitev robnega problema $z' = f(x, z)$, $z(x_n) = y(x_n)$.

Globalna napaka je vsota globalne napake na prejšnjem koraku in lokalne napake na zadnjem koraku.

Lokalna napaka je reda $p \in \mathbb{N}$, če za neko konstanto C velja $y_{n+1} - z(x_{n+1}) = Ch^{p+1} + \mathcal{O}(h^{p+2})$.

Enokoračne eksplcitne metode

Eulerjeva metoda (1. red):

$y_{n+1} = y_n + hf(x_n, y_n)$

Metoda Runge-Kutta 4. reda:

$k_1 = hf(x_n, y_n)$

$k_2 = hf\left(x_n + \frac{h}{2}, y_n + \frac{k_1}{2}\right)$

$k_3 = hf\left(x_n + \frac{h}{2}, y_n + \frac{k_2}{2}\right)$

$k_4 = hf(x_n + h, y_n + k_3)$

$y_{n+1} = y_n + \frac{1}{6}(k_1 + 2k_2 + 2k_3 + k_4)$

Večkoračne eksplcitne metode

Nova vrednost k -koračne y_{n+1} je odvisna od

$y_n, y_{n-1}, \dots, y_{n-k+1}$. Začetne vrednosti določimo z neko eksplcitno enokoračno metodo istega reda.

Najbolj znane so Adams-Bashforthove metode, ki jih izpeljemo z integriranjem interpolacijskega polinoma za funkcijo $f(x, y(x))$.

Dvokoračna Adams-Bashforthova metoda:

$y_{n+1} = y_n + \frac{h}{2}(3f(x_n, y_n) - f(x_{n-1}, y_{n-1}))$

Enokoračne implicitne metode

Splošna oblika je $y_{n+1} = \Phi(h, x_n, y_n, y_{n+1}, f)$.

Za izračun y_{n+1} moramo rešiti (nelinearno) enačbo.

Najpogostejše to naredimo kar z iteracijo $y_{n+1} = \tilde{\Phi}(y_{n+1})$, ki

konvergira, če $\left| \frac{\partial \Phi}{\partial y}(h, x_n, y_n, y, f) \right| \leq 1$ (vedno za dovolj majhen h). Za začetni približek vzamemo y_{n+1} po neki eksplcitni metodi.

Trapezna metoda (2. red):

$y_{n+1} = y_n + \frac{h}{2}(f(x_n, y_n) + f(x_{n+1}, y_{n+1}))$

Sistemi ODE 1. reda

Rešujemo

$y'_1 = f_1(x, y_1, y_2, \dots, y_d)$

$\vdots$

$y'_d = f_d(x, y_1, y_2, \dots, y_d)$

pri pogojih $y_1(a) = y_{1a}, \dots, y_d(a) = y_{da}$

Če uvedemo $\mathbf{Y} = \begin{bmatrix} y_1 & y_2 & \dots & y_d \end{bmatrix}^T$ in

$\mathbf{F} = \begin{bmatrix} f_1 & f_2 & \dots & f_d \end{bmatrix}^T$, dobimo $\mathbf{Y}' = \mathbf{F}(x, \mathbf{Y})$, $\mathbf{Y}(a) = \mathbf{Y}_a$, kar pa lahko rešujemo s katero koli metodo za reševanje ODE 1. reda prepisano v vektorsko obliko.

ODE višjih redov

Rešujemo $z^{(k)} = f(x, y, y', \dots, y^{(k-1)})$ pri pogojih

$$y(a) = y_a, y'(a) = y'_a, \dots, y^{(k-1)}(a) = y_a^{(k-1)}.$$

S substitucijami $y_1 = y, y_2 = y', \dots, y_k = y^{(k-1)}$ prevedemo problem na sistem:

$$y'_1 = y_2$$

$$\vdots$$

$$y'_{k-1} = y_k$$

$$y'_k = f(x, y_1, \dots, y_k)$$

pri pogojih $y_1(a) = y_a, y_2(a) = y'_a, \dots, y_k(a) = y_a^{(k-1)}$

Robni problem 2. reda

Rešujemo $y'' = f(x, y, y')$ pri pogojih $y(a) = \alpha, y(b) = \beta$

Linearni robni problem 2. reda

Rešujemo $-y'' + py' + qy = r, y(a) = \alpha, y(b) = \beta$, kjer so p, q, r dane zvezne funkcije.

Rešimo 2 začetna problema oblike

$-y'' + py' + qy = r, y(a) = \alpha, y'(a) = \delta_i$, za neka δ_i in dobimo rešitvi y_1, y_2 .

Enačbo reši tudi $y = \lambda y_1 + (1 - \lambda)y_2, \lambda \in \mathbb{R}$. Avtomatsko velja

$$y(a) = \alpha, \text{ iz zahteve } y(b) = \beta \text{ pa dobimo } \lambda = \frac{\beta - y_2(b)}{y_1(b) - y_2(b)}.$$

Če je $y_1(b) = y_2(b)$ izberemo drugačne δ_i .

Metoda končnih diferenc

Izberemo ekvidistante delilne točke $a = x_0 < \dots < x_{n+1} = b$, $h = x_{i+1} - x_i$ in uporabimo simetrične približke odvodov.

Če označimo $p_i = p(x_i), q_i = q(x_i)$ in $r_i = r(x_i)$ dobimo:

$$y_1(2 + h^2 q_1) + y_2 \left(-1 + \frac{h}{2} p_1 \right) = h^2 r_1 - \alpha \left(-1 - \frac{h}{2} p_1 \right)$$

$$y_{i-1} \left(-1 - \frac{h}{2} p_i \right) + y_i(2 + h^2 q_i) + y_{i+1} \left(-1 + \frac{h}{2} p_i \right) = h^2 r_i, \text{ za } i = 2, 3, \dots, n-1$$

$$y_{n-1} \left(-1 - \frac{h}{2} p_n \right) + y_n(2 + h^2 q_n) = h^2 r_n - \beta \left(-1 + \frac{h}{2} p_n \right)$$

Ta sistem je tridiagonalen in diagonalno dominanten.

Nelinearni robni problem 2. reda

Metoda končnih diferenc za nelinearen problem

Izberemo ekvidistante delilne točke $a = x_0 < \dots < x_{n+1} = b$, $h = x_{i+1} - x_i$ in uporabimo simetrične približke odvodov.

$$\text{Dobimo } y_{i-1} - 2y_i + y_{i+1} = h^2 f \left(x_i, y_i, \frac{y_{i+1} - y_{i-1}}{2h} \right),$$

$i = 1, \dots, n$. To je sistem n nelinearnih enačb.

Streška metoda

Začetni problem rešimo z nekim $y'(a) = k_0$ in dobimo rešitev $y(x; k_0)$. Definiramo $F(k) = y(b; k) - \beta$ in iščemo rešitev enačbe $F(k) = 0$.

Ponavadi se to rešuje s sekantno metodo

$$k_{r+2} = k_{r+1} - \frac{F(k_{r+1})(k_{r+1} - k_r)}{F(k_{r+1}) - F(k_r)}, \text{ kjer na vsakem koraku}$$

rešimo ODE 2. reda z $y'(a) = k_r$.